



中南大學

CENTRAL SOUTH UNIVERSITY

本科毕业设计（论文）

GRADUATION DESIGN (THESIS)

题 目:	基于病理图像的肺癌生存风险预测系统
学 生:	朱志文
学 号:	8208221110
专业班级:	大数据 2203 班
指导教师:	匡湖林
学 院:	计算机学院

本科生院制

2026 年 5 月

基于病理图像的肺癌生存风险预测系统

摘要

肺癌作为全球范围内发病率与死亡率最高的恶性肿瘤之一，其精准的生存风险预测对于制定个体化精准医疗方案具有深远的意义。随着数字病理技术的飞速变革，全切片图像（WSI）已成为癌症诊断的金标准，但其巨大的像素规模和复杂的组织异质性给临床预后评估带来了分析效率低、单一模型泛化能力有限以及算法成果难以工程化落地等挑战。针对这些问题，本文设计并实现了一个基于集成学习的端到端肺癌生存风险预测系统。本系统深度整合了 RRTMIL、AMIL、WiKG、DSMIL 以及 S4MIL 等多种主流的多实例学习模型，并在此基础上提出了一种决策层集成方案。该方案通过对各分支模型的风险概率进行加权融合，并引入最优分支蒸馏与稳健门控回退机制，有效提升了预测结果的稳定性与准确性上限，在 TCGA-LUSC 数据集上的实验证明，集成模型在 C-index 等核心指标上均优于单一基线模型。

在系统实现层面，本文构建了以 Flask 和 Gunicorn 为后端服务、React 为前端交互界面的全栈架构。系统打通了病理数据上传、特征在线抽取、任务排队调度、模型训练监控、性能多维评估以及在线推理预测的全流程闭环。同时，为了提升系统的可维护性与可复现性，本文提供了容器化部署方案，实现了从底层算法研究到应用平台展示的完整技术路径。本文的工作不仅为病理图像驱动的肺癌风险分层研究提供了有力工具，也为临床辅助决策系统的开发提供了可扩展的技术参考。

关键词：肺癌；全切片图像；生存风险预测；特征级集成；系统实现

Lung Cancer Survival Risk Prediction System Based on Pathological Images

ABSTRACT

Lung cancer is one of the most prevalent and lethal malignant tumors worldwide. Accurate survival risk prediction for lung cancer is of great significance for the formulation of individualized precision medical plans. With the rapid transformation of digital pathology technology, whole-slide images (WSI) have become the gold standard for cancer diagnosis. However, their large pixel size and complex tissue heterogeneity pose challenges such as low analysis efficiency, limited generalization ability of a single model, and difficulty in engineering the algorithmic outcomes. To address these issues, this paper designs and implements an end-to-end lung cancer survival risk prediction system based on ensemble learning. This system deeply integrates multiple mainstream multi-instance learning models such as RRTMIL, AMIL, WiKG, DSMIL, and S4MIL, and proposes a decision-level integration scheme. This scheme effectively integrates the risk probabilities of each branch model through weighted fusion and introduces the optimal branch distillation and robust gated backpropagation mechanism, thereby significantly improving the stability and upper limit of accuracy of the prediction results. Experimental results on the TCGA-LUSC dataset demonstrate that the integrated model outperforms the single baseline model in core indicators such as C-index.

At the system implementation level, this paper has constructed a full-stack architecture using Flask and Gunicorn as the backend services and React as the front-end interaction interface. The system has integrated the entire process loop of pathological data upload, online feature extraction, task queuing scheduling, model training monitoring, multi-dimensional performance evaluation, and online inference prediction. At the same time, in order to enhance the maintainability and

reproducibility of the system, this paper provides a containerized deployment solution, achieving a complete technical path from the underlying algorithm research to the application platform presentation. The work of this paper not only provides a powerful tool for the research of lung cancer risk stratification driven by pathological images, but also offers an expandable technical reference for the development of clinical auxiliary decision-making systems.

Key words: Lung Cancer; Complete Section Image; Survival Risk Prediction; Feature-Level Integration; System Implementation

目录

第一章	绪论	1
1.1	研究背景及意义	1
1.2	国内外研究现状	2
1.2.1	多实例学习在分析全切片图像的应用	2
1.2.2	Transformer 与全切片图像	2
1.2.3	面向多实例学习的图神经网络方法	3
1.3	主要研究内容	3
1.4	本文组织架构	4
第二章	相关技术与数据集介绍	5
2.1	多实例学习技术	5
2.2	Transformer 技术	5
2.3	视觉-语言模型技术	6
2.4	状态空间模型技术	7
2.5	生存分析技术	7
2.6	图神经网络技术	7
2.7	数据集介绍	8
第三章	基于决策层集成的肺癌风险分层方法	10
3.1	引言	10
3.2	集成方法概述	10
3.2.1	问题定义	10
3.2.2	方法流程	11
3.3	重嵌入区域 Transformer 模型	12
3.4	基于注意力机制的深度多示例学习模型	13
3.5	双流多示例学习模型	14
3.6	结构化状态空间模型	16
3.7	基于知识图谱注意力机制的动态图表示学习模型	17
3.8	基于自适应加权的集成学习策略	19
3.8.1	基线池、参与方式与融合权重选择策略	19
3.8.2	决策层 avg_prob 融合与基础风险	20
3.8.3	蒸馏、双任务 tiebreak 与稳健门控	21
3.9	模型训练	22
3.9.1	数据构建、样本规模与训练环境及划分协议	22
3.9.2	数据加载、特征形式与训练流程	25
3.9.3	评价指标	25
3.10	实验与结果	26
第四章	系统设计与实现	29
4.1	系统需求分析	29
4.2	系统总体架构	30
4.3	系统流程	31
4.4	系统前端设计与实现	34
4.5	系统后端设计与实现	35

4.6 系统界面展示.....	36
第五章 总结与展望	43
5.1 总结.....	43
5.2 展望.....	43
致谢.....	44
参考文献.....	45

第一章 绪论

1.1 研究背景及意义

肺癌作为我国及世界范围内发病率和死亡率最高的恶性肿瘤之一，已成为威胁人类公共健康的头号杀手。在我国，其发病率的持续走高对整个医疗体系构成了严峻挑战。随着低剂量计算机断层扫描的普及，我国肺癌的检出率逐年升高，全球癌症生存趋势监测报告数据显示^[26]，2000~2014年间肺癌的年龄标化5年生存率波动在10%~20%之间，在中国，肺癌的年龄标化5年生存率在2003~2015年间略有上升的趋势，但仍低于20.0%；2012~2015年中国人群肺癌的5年生存率仅为19.7%。影响肺癌5年生存率的关键因素在于临床诊断时的肿瘤分期。临床研究数据显示，早期肺癌的5年生存率可达61.2%，其中小于1 cm的I期肺癌的5年生存率达92%；而晚期肺癌的5年生存率仅7.0%。因此，早期预测对于改善肺癌患者的预后至关重要。

长时间内，临床预后评估主要凭借传统的（Tumor, Node, Metastasis Staging System, TNM）分期系统，就是基于肿瘤大小、淋巴结受累及远端转移情况进行分层。但是，这个系统主要依赖肿瘤大小、淋巴结受累及远处转移等一系列宏观的解剖学指标，在评估肿瘤内部生物学行为的多态性及个体异质性方面存在着显著的局限。临床上迫切需要一种能够整合微观形态学特征的生存风险预测系统，可以在术后特定时间内预测患者复发或死亡概率的量化模型。随着计算病理学的发展，其中代表性的多示例学习（Multiple Instance Learning, MIL）在组织病理学全切片图像（Whole Slide Images, WSI）分析中展现出巨大的潜力，可用于癌症的诊断和预后。全切片图像（WSI）以千兆像素级别的超高分辨率，完整保留了肿瘤组织的空间结构与形态细节，为精准诊断提供了条件。本文将讨论集成多种MIL方法，深度挖掘WSI中蕴含的判别性视觉模式，构建一个基于病理图像的肺癌生存风险预测系统。

本研究的动机来源于临床决策中海量病理数据与人工评估局限的深层矛盾。但是WSI固有的空间异质性带来了严峻的挑战，因为形态相似的组织类型往往

分散在不同的解剖区域，传统的 MIL 方法难以有效地对这些分散的组织分布进行建模，也难以捕捉跨区域的空间相互作用。由于监督信号较弱，模型也容易出现过拟合问题，为了克服这些局限性，本文研究了五种基于 MIL 的优化方法并对他们进行集成。

1.2 国内外研究现状

1.2.1 多实例学习在分析全切片图像的应用

自从 1997 年 Dietterich 等^[32]提出了多实例学习 (MIL)，最早用于解决药物活性预测中的问题，核心思想如下：数据由包 (bag) 组成，每个包包含多个实例 (instances)，但只有包有标签，实例标签信息不明确。这种学习框架适用于无法明确标注单个实例的任务，因此非常适合处理复杂数据集。目前，国内外的学者将 MIL 推进更广泛的应用，并在医学图像分析领域取得了一定研究进展。由于 MIL 是一种弱监督学习方法，因此特别适用于全切片图像 (WSI) 分析任务。WSI 的分辨率极高，每幅图像由大量像素构成，无法精确标注每个像素或小块。而 MIL 将这些高像素图像视为一个包，对于其中包含的多个实例，模型仅须标记整个袋子，无须逐个标记每个实例。换句话说，只要袋子中至少包含一个阳性实例，那么整个袋子就会被标记为阳性。这使得 MIL 尤其适用于 WSI 中的肿瘤检测和分类等任务，诞生了一系列基于 MIL 的方法：RRTMIL^[12]、AMIL^[17]、WiKG^[29]、DSMIL^[14]、S4MIL^[31]。

1.2.2 Transformer 与全切片图像

Transformer^[34]最初应用于自然语言处理领域，是一种主要基于自注意力机制的深度神经网络。由于其强大的表征能力，研究人员正在探索如何将 Transformer 应用于计算机视觉任务。在各种视觉基准测试中，基于 Transformer 的模型表现与其他类型的网络（如卷积神经网络和循环神经网络）相当甚至更优。鉴于其高性能以及对特定视觉归纳偏置的较少需求，Transformer 正受到计算机视觉领域越来越多的关注。然而，将 Transformer 应用于全切片图像 (WSI) 的生存分析任务仍存在两个主要问题。首先，生存分

析的训练数据有限,使得模型容易过拟合。对于需要大规模数据进行训练的基于 Transformer 的模型而言,这个问题更为严重。其次,WSI 具有极高的分辨率,并且通常以多分辨率金字塔的形式组织。传统的 Transformer 无法对 WSI 的层次结构(例如图像块聚类级关系)进行建模,因此无法学习层次化的 WSI 表示。为了解决这些问题,Yan R 等^[6]学者提出一种基于 Transformer 的方法为建模千兆像素全切片图像(WSI)的全局上下文提供了良好的契机,引入稀疏自注意力机制来缓解过拟合问题,并提出了一种分层 Transformer 结构来学习分层 WSI 表示。

1.2.3 面向多实例学习的图神经网络方法

图神经网络(Graph Neural Network, GNN)是指使用神经网络来学习图结构数据,提取和发掘图结构数据中的特征和模式,满足聚类、分类、预测、分割、生成等图学习任务需求的算法总称。它依托图节点间的信息传递与特征聚合机制,能够高效建模数据间的关联结构,打破了传统算法假设数据独立同分布的固有局限。根据 Tu M 等^[35]的研究,在多实例学习(MIL)这一典型弱监督学习场景中,GNN 展现出极强的适配性:可将包含多个实例的样本包转化为图结构,以实例作为图节点、实例间的相似度关联作为图边,通过图表征学习深度挖掘包内实例的结构信息,再经可微池化或注意力聚合得到固定维度的包嵌入,最终完成包级标签预测。该思路在药物活性预测、文本分类、糖尿病视网膜影像诊断等任务中均实现了性能突破,同时还能通过节点分配矩阵定位对决策起关键作用的实例,在提升模型效果的同时保留可解释性,为弱监督图学习任务提供了全新的高效解决方案。

1.3 主要研究内容

正是由于全切片图像(WSI)具有超高分辨率与实例数量巨大的特点,因此在有限算力下同时兼顾全局上下文建模与细粒度预后线索成为难点。另一方面,临床决策不仅关心风险分层是否准确,还希望模型输出能够与病理形态学证据建立可追溯联系,以降低黑箱应用门槛。此外,真实数据往往来自不同中心、染色与扫描条件,模型若缺乏稳健性与可复现流程,结论难以落地。

针对上述问题，本文以肺癌生存预测与风险分层为应用场景，在统一任务定义与数据表示的前提下，围绕多种 MIL 基线方法开展研究，对 5 种 MIL 基线方法进一步多分支特征级集成，通过融合互补模型的表征能力，提升预测稳定性与上限，并形成可重复的实验结论。最后，将训练调度、数据与病例管理、模型评估与可视化、在线推理及容器化部署贯通为 API + Web + 网关的一体化平台，把方法验证与工程可交付纳入同一研究闭环。

1.4 本文组织架构

第一章为绪论，简要说明了病理全切片图像与肺癌生存分析的研究背景，分析了当前临床评估的局限性与工程化落地的难点，并明确了本文的研究内容。

第二章对相关技术基础与数据集进行了系统性介绍，涵盖了多实例学习、Transformer、状态空间模型、图神经网络等核心理论，并详细说明了本文所采用的 TCGA-LUSC 数据集的构成与处理流程。

第三章是本文算法研究的核心，详细论述了基于决策层集成的肺癌风险分层方法。本章不仅深入剖析了 RRTMIL^[12]、AMIL^[17]、WiKG^[29]、DSMIL^[14]、S4MIL^[31]这五种特定 MIL 基线模型的架构细节，还重点提出了本文的自适应加权集成策略。通过设置严谨的评价指标（如 C-index）与训练协议，本章对单一基线模型与集成模型进行了详实的对比实验与分析。

第四章则聚焦于系统的设计与落地，从需求分析出发给出了系统的总体架构，详细说明了基于 Flask 的后端 API 开发、基于 React 的前端模块构建以及容器化部署方案，并通过界面展示了从数据管理到在线预测的完整业务流程。

第五章总结了全文的研究成果与结论，并指出了当前工作的不足之处，为后续在多模态融合及临床落地等方向的研究指明了展望方向。

第二章 相关技术与数据集介绍

2.1 多实例学习技术

多实例学习（Multiple Instance Learning, MIL）是计算病理学中处理全切片图像（WSI）的核心弱监督学习框架。在肺癌预测场景中，整张切片被视为一个包（Bag），而从切片中裁剪出的数万个补丁（Patches）则被视为“实例”（Instances）。MIL 的核心挑战在于包的标签（如生存时间）已知，但实例的标签未知。

技术演进从早期的最大值/均值池化逐步过渡到目前的深度参数化池化。目前最权威的技术是基于注意力的多实例学习（Attention-based MIL）^[17]，其核心公式是基于注意力的权重分配计算如公式 1 所示，它引入了神经网络来学习一个加权函数，能够自动赋予判别性斑块（如包含气腔播散 STAS 的区域）更高的权重。最新的研究（如 HVTSurv^[9]）将此概念扩展到包中包的分层结构，以处理患者级别的多切片聚合，有效解决了肺癌组织内高度异质性导致的特征淹没的问题。

$$a_k = \frac{\exp\{w^T \tanh(Vh_k^T)\}}{\sum_{j=1}^n \exp\{w^T \tanh(Vh_j^T)\}}, \quad (1)$$

a_k 是第 k 个病理斑块实例的注意力权重，代表该斑块对生存风险预测的贡献。 h_k 是第 k 个病理斑块经特征提取器得到的特征向量。 w 是注意力模块的可学习参数向量，用于计算斑块的重要度分数。 V 是可学习的权重变换矩阵。 n 是该全切片图像（WSI）中所包含的斑块总数。

2.2 Transformer 技术

视觉变换器（Vision Transformer）及其衍生架构通过自注意力（Self-attention）机制彻底改变了病理图像的全局建模方式。传统的卷积神经网络（CNN）受限于局部感受野，难以捕获肺癌组织中跨区域的拓扑关联（如肿瘤

边缘与免疫细胞浸润的空间关系)。Transformer 能够将整张 WSI 视为一个序列, 通过建立补丁间的成对相关性, 捕获长程依赖关系 (Long-range Dependencies)。

在肺癌生存分析中, Transformer 的应用解决了上下文感知问题。例如, 由 Shao Z 等^[5]提出的 TransMIL 模型利用 Transformer 结构打破了斑块独立同分布的假设, 实现了对肿瘤微环境 (TME) 的结构化解析。然而, 由于 WSI 序列极长, 直接应用面临巨大的显存开销, 因此目前的技术趋势是结合分窗注意力和分层架构, 在保留全局视野的同时, 提高处理肺癌复杂异质性组织的计算效率, 其核心公式是缩放点积注意力 (Scaled Dot-Product Attention) 如公式 2。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (2)$$

Q 是查询矩阵, 代表斑块寻求与其他区域关联的特征。 K 是键矩阵, 代表斑块本身作为参照物被匹配的特征。 V 是值矩阵, 代表斑块包含的实际病理学信息。 d_k 是特征向量的维度。 softmax 是激活函数, 将相关性得分转化为总和为 1 的概率分布。

2.3 视觉-语言模型技术

视觉-语言模型 (Vision-Language Model, VLM) 旨在通过跨模态学习, 实现视觉图像表征与语义标签 (如诊断报告、基因描述) 的深度对齐。在肺癌生存预测中, VLM 技术可以将病理形态特征与抽象的生物学概念 (如基因信号通路) 结合, 利用 VLM 的对比学习思想, 将 WSI 的视觉斑块特征与转录组学 (Transcriptomics) 中的生物通路标记映射到同一特征空间。

这种技术的应用意义在于极大地提升了系统的临床可解释性。传统的模型仅输出风险评分, 而 VLM 驱动模型能让 AI 理解特定的病理视觉模式对应于哪种生物学机理 (如上皮-间质转化 EMT)。通过对比损失函数训练, 系统能学习到超越单一模态的鲁棒特征, 即便在缺少部分生物学数据的情况下, 也能通过病理图像精准推断患者的生存风险, 为实现病理-基因-生存的多维度协同预测提供了可能。

2.4 状态空间模型技术

状态空间模型（State Space Model, SSM）是以 Mamba^[36]为代表的新一代长序列建模技术。针对处理肺癌 WSI 时 Transformer 面临的平方级计算复杂度难题，SSM 通过线性循环（Linear Recurrence）或卷积实现状态转换，具备 $O(n)$ 的线性计算效率。其核心思想是将超长的补丁序列映射到一个连续的隐藏状态空间中，实现对全局记忆的高效压缩。

在肺癌风险评估中，SSM 模型通过引入选择性扫描机制（Selective Scan），能够有效识别并遗忘全切片中的无意义背景区域，同时精准保留具有高预后价值的微小病变特征。SSM 的离散化形式使其既具备了 Transformer 的长时记忆能力，又保留了 RNN 模型的高推理速度，是目前解决千兆像素级别 WSI 全量数据输入且不丢失特征细节的最佳路径，尤其适用于大规模临床肺癌预测系统。

2.5 生存分析技术

生存分析是肺癌风险预测系统的统计学基石。不同于传统的二分类任务，生存分析旨在处理删失（Censoring）数据，即患者由于失访或随访结束时尚未死亡导致的数据不完整性。生存分析模型的目标是估算危害函数（Hazard Function），即患者在特定时间点的瞬时死亡风险。

深度生存模型通常采用 Cox 比例风险模型的负对数偏似然函数作为损失。近年来，离散时间生存模型（如 HVTSurv^[9]）逐渐受到关注，它通过将生存期划分为若干时间区间，利用累积生存概率预测患者在术后 1 年、3 年或 5 年等特定节点的生存曲线。这种技术确保了肺癌预测系统不仅能给出一个静态评分，还能提供动态的生存预测，也为临床医生调整治疗方案提供统计学依据。

2.6 图神经网络技术

图神经网络（Graph Neural Network, GNN）通过将全切片图像（WSI）建模为图结构，捕获斑块间的空间几何关系。在图中，每个病理斑块被视为一个节点，空间相邻或解剖上相关的斑块通过边连接。这种建模方式天然符合病理

组织的组织学特性，因为癌细胞与免疫细胞、血管及纤维基质的物理距离和拓扑连接直接反映了肺癌的侵袭性。

GNN 技术的核心优势在于消息传递机制（Message Passing），通过多层图卷积，节点可以聚合其邻域内的特征信息，从而识别出复杂的组织模式（如肿瘤腺管结构）。代表性研究如 Patch-GCN，它利用 GNN 在 WSI 上构建空间交互网络，不仅能提升分类精度，还能通过图结构的可视化定位肺癌的关键侵袭前沿，为生存分析提供具有病理学解释性的解剖结构支撑，其核心公式如公式 3 所示。

$$h_v^{(k)} = \sigma \left(W \cdot \text{CONCAT} \left(h_v^{(k-1)}, \text{AGG} \left(\{h_u^{(k-1)}\}, \forall u \in \mathcal{N}(v) \right) \right) \right), \quad (3)$$

$h_v^{(k)}$ 是斑块节点 v 在第 k 层更新后的语义特征表示。 $\mathcal{N}(v)$ 是节点 v 的邻域补丁集合（通常指物理距离相邻的斑块）。 $\text{AGG}(\cdot)$ 是聚合算子，负责将周围邻居斑块的信息压缩并传递给当前节点。 CONCAT 是向量拼接操作，用于融合节点自身的旧特征与邻域的新特征。 W 是可学习的权重变换矩阵。 σ 是非线性激活函数，增加模型的拟合能力。

2.7 数据集介绍

本文采用癌症基因组图谱（The Cancer Genome Atlas, TCGA）中的肺鳞状细胞癌（Lung Squamous Cell Carcinoma, LUSC）数据集^[30]。TCGA 是 2005 年由美国国立癌症研究所（NCI）与国家人类基因组研究所（NHGRI）联合发起的大型国际研究计划，旨在通过大规模基因组测序与多维整合分析，系统性 catalogue 并解析 30 余种人类肿瘤的致癌基因组变异，构建全面的癌症基因组图谱。构建了迄今为止最全面、最深度的癌症数字基因组蓝图。该项目通过高度严谨的多中心协作流程，实现了样本采集、病理质控、分子测序及数据分析的全生命周期管理，不仅极大地推动了肿瘤异质性与精准医学的研究进程，还通过等级规范化的数据管理机制，将海量组学数据向全球科研界公开共享，成为支撑当代计算肿瘤学与人工智能辅助诊断研究的基石。

在系统实现中，本文聚焦于肺鳞状细胞癌（LUSC）数据集。TCGA-LUSC 不仅提供了详尽的患者随访记录，更整合了极具深度的多维组学矩阵，涵盖了转录组层面的 RNA 测序与 microRNA 分析、基因组层面的 DNA 突变检测与甲基化修饰、蛋白质水平的反向蛋白芯片（RPPA）数据，以及单核苷酸多态性（SNP）分型等关键生物指标。对于计算病理学研究而言，该数据集配套的高分辨率全切片图像（WSI）具有极高的科学价值，每份图像均经过权威病理学家的严格复核与分型标注，确保了诊断结果的金标准地位。这种跨越分子、细胞与组织层面的立体化数据网络，不仅支持研究者深入探究组织形态学特征与潜在分子变异之间的关联，也为验证多实例学习（MIL）等弱监督算法在复杂病理场景下的分类性能、生存预测及生物标志物发现提供了权威且具备高度异质性的实验基准。本研究将样本按病例进行组织，并构建双尺度病理特征输入，训练与评估采用 K 折交叉验证，并在病例级进行数据划分以避免信息泄漏。对于缺失关键标签或特征文件的样本予以剔除，TCGA-LUSC 数据集在本研究中不仅用于模型训练，还贯穿了数据管理、模型评估与推理验证等核心环节。首先，作为多实例学习模型（RRTMIL^[12]、AMIL^[17]、WiKG^[29]、DSMIL^[14]、S4MIL^[31]）的主要训练与验证数据来源，用于学习病理切片的类别判别特征。其次，还作为标准样本来源，验证从特征读取、模型加载到结果输出的完整推理链路稳定性。

第三章 基于决策层集成的肺癌风险分层方法

3.1 引言

全切片病理图像（WSI）具有超高分辨率、强异质性与弱标注的特征。直接端到端训练存在显存压力大、样本有效监督弱、跨病例分布漂移明显等问题。所以采取先将 WSI 转化为 *patch* 级特征，再通过多实例学习（MIL）模型完成病例级风险预测。不同多实例学习（MIL）结构具有不同归纳偏置，重嵌入区域 Transformer (Re-embedded Regional Transformer, RRTMIL)^[12] 偏向全局关系建模，基于注意力机制的深度多示例学习（Attention-based Deep Multiple Instance Learning, AMIL）^[17] 强调关键实例加权，基于知识图谱注意力机制的动态图表示学习模型（Dynamic Graph Representation, WiKG）^[29] 利用图结构信息，双流多示例学习（Dual-stream Multiple Instance Learning, DSMIL）^[14] 通过双分类器稳定弱监督学习，结构化状态空间模型（Structured State Space Models, S4MIL）^[31] 在长序列建模方面具备优势。单模型往往对特定数据分布敏感，易出现某一任务最优、跨任务不稳定的现象。因此，本文采用决策级集成而非可训练特征级融合头，在推理阶段融合多基线输出概率，并引入最优分支蒸馏、双模型轻量校准和稳健回退保护的策略，以提升预测层面的 $C-index$ 稳定性与可复现性。

3.2 集成方法概述


3.2.1 问题定义

模型输入 TCGA-LUSC 的全切片图像（WSI）的 *patch* 特征集合，每个 *patch* 表示为 d 维向量，模型输出该病例的生存风险评分（分数越高表示风险越高），训练监督来自生存时间与删失状态，优化目标是在可比较病例对上尽可能提高风险排序与真实生存结局的一致性，设病例的 *patch* 特征 bag 为：

$$\mathcal{X} = x^1, x^2, \dots, x^N, \text{ 且 } x_i \in R^d, \quad (4)$$

其中 $\mathcal{X}$ 表示一个病例对应的 $patch$ 特征集合（bag）， x_i 表示第 i 个 $patch$ 的特征向量， i 表示 $patch$ 索引， N 表示该病例包含的 $patch$ 总数， R^d 表示 d 维实数向量空间， d 表示每个 $patch$ 特征的维度。

生存分析样本记为 (T, δ) ，其中 T 为生存时间， $\delta \in \{0, 1\}$ 为删失指示。目标是学习风险评分函数 $r(\mathcal{X})$ ，使预测风险在可比较样本对上的排序尽量与真实结局一致，评价指标采用 $Harrell C-index$ ，可比较样本对就是在统计上可以判定先后顺序的病例对，若模型能在更多此类病例对上给出正确先后排序，则 $C-index$ 越高。



图表 1 基于决策层集成的肺癌风险分层方法流程图

3.2.2 方法流程

图表 1 展示了本集成方法的完整流程，方法的核心思想是将五种 MIL 模型的预测能力集成。首先在概率空间执行平均融合，得到基础风险估计，随后结合历史排序信息识别最优分支与次优分支，在不重训主干模型的前提下进行小幅方向性校准，当验证集提升不足或全量指标出现退化时，系统自动回退到 $\lambda=0$ ，以保证模型表现的稳定性与可复现性。方法输入为同一病例的多分支预测证据，输出为病例级最终风险分数。上层模块解决如何把多分支信息合成为一

个基础风险估计的问题，下层模块解决在不破坏稳定性的前提下如何进一步改善排序的问题。对应实现中，上层完成基础概率融合并生成 r_{base} ，下层依次执行最优分支优先、双分支 λ 校准与稳健回退判定，其中集成方法具体的选择策略将在 3.8 小节陈述。

3.3 重嵌入区域 Transformer 模型

重嵌入区域 Transformer (RRTMIL)^[12] 是一种旨在提升计算病理学多实例学习性能的新型范式。传统的 MIL 架构通常采用离线特征提取模式，在 ImageNet 或病理基础模型上预训练好的特征提取器获取固定特征，这种方式由于特征不再更新，往往难以适配特定的下游任务。RRTMIL 核心思想是引入一个在线特征重嵌入层，在保持计算效率的同时，还能对离线特征进行任务相关的精炼。

在结构上，RRTMIL 模块首先将 WSI 提取出的实例特征序列（通常视为一维）通过平方化（Squaring）操作还原为二维网格布局，随后将其划分为多个 $L \times L$ 的局部区域。模型的核心处理流程遵循以下公式：

$$\hat{Z} = R - MSA(LN(H)) + H, \quad Z = CR - MSA(LN(\hat{Z})) + \hat{Z}, \quad (5)$$


其中， H 代表输入的离线实例特征矩阵，LN 表示层归一化（Layer Normalization）操作，用于稳定特征分布， $R - MSA$ 代表区域多头自注意力，负责提取局部区域内的细粒度形态信息，输出中间状态 $\hat{Z}$ ， $CR - MSA$ 则代表跨区域多头自注意力，通过在各区域间建立远程依赖得到最终的重嵌入特征 Z 。

此外，为了有效编码位置信息，模型引入了嵌入式位置编码生成器 (Embedded Position Encoding Generator, EPEG)。EPEG 摒弃了传统的固定位置嵌入，改用深度可分离卷积动态提取空间特征，其注意力权重 α 的计算公式为：

$$\alpha_{ij}^l = SoftMax \left(e_{ij}^l + Conv_{1-D}(e_{ij}^l) \right), \quad (6)$$

其中 α_{ij}^l 表示第 l 个区域内第 i 个与第 j 个实例间的注意力分值； e_{ij}^l 是通过缩放点积计算的原始注意力能量； $Conv_{1-D}$ 则代表模型引入的嵌入式位置编码生成器

（EPEG）所使用的轻量化一维卷积，它作用于注意力矩阵以动态捕捉实例间的空间序关系。



图表 2 RRT-MIL 模型概述。首先从切片的组织区域裁剪出一组补丁，并通过离线提取器嵌入特征。然后，该序列通过 R2T 模块进行处理：区域划分、每个区域内的特征重新嵌入、跨区域特征融合。最后，MIL 模型使用重新嵌入的实例特征预测袋标签。

图表 2 展示了 RRT-MIL 的端到端流程，输入阶段从全切片图像（WSI）中切割出的 *patch* 经过离线提取器得到特征，重嵌入阶段经过 Squaring 与 Partition 划分区域，通过 R-MSA 进行区域内信息交换，再利用 CR-MSA 完成跨区域通信，输出阶段把重嵌入后的特征 Z 被送入 MIL 聚合器进行最终的标签预测。该图清晰地体现了 RRTMIL 作为一个便携式插件如何无缝集成到主流 MIL 模型中，从而将 ResNet-50 级别的特征提升至基础模型水平。

3.4 基于注意力机制的深度多示例学习模型

基于注意力机制的深度多示例学习（Attention-based Deep Multiple Instance Learning, AMIL）是由阿姆斯特丹大学的 Maximilian Ilse 等人^[17]提出，是 MIL 领域最具影响力的奠基性工作之一。该模型首次将可学习的注意力机制引入 MIL 框架，解决了传统平均池化或最大池化在面对复杂切片时权重分配过于僵化的问题。AMIL 将 WSI 分析视为一个学习实例重要性分布的过程，通过神经网络自动学习每个 *patch* 对最终诊断结果的贡献度。

在模型实现上，AMIL 采用了嵌入级（Embedding-level）聚合方案。假设一个包（Bag）包含 K 个实例特征 $H = \{h_1, \dots, h_k\}$ ，聚合后的包表示 z 的计算公式如下：


$$z = \sum_{k=1}^K a_k h_k, \quad (7)$$

其中 z 是聚合后的包级向量， K 是包中包含的实例总数， h_k 是第 k 个实例的特征向量， a_k 是对应的可学习权重。

权重 a_k 的核心计算逻辑采用门控注意力机制，图表 3 直观展示了 AMIL 的解释性能力。在 MNIST-bags 示例中，包标签取决于是否包含数字 9。实验结果显示，模型赋予数字 9 的注意力权重（如 $a_6 = 0.24766$, $a_9 = 0.28002$ ）显著高于其他背景数字（均接近 0）。这种权重可视化技术被广泛应用于病理切片的 ROI（感兴趣区域）自动定位，辅助病理医生快速定位癌变区域。 a_k 计算公式为：

$$a_k = \exp w^T (\tanh(Vh_k^T) \odot \text{sigm}(Uh_k^T)) / \sum_{j=1}^K \exp w^T (\tanh(Vh_j^T) \odot \text{sigm}(Uh_j^T)), \quad (8)$$

其中 w 是一个可学习的投射向量，用于将高维特征映射为标量权重， V 和 U 是两个独立的参数矩阵，分别用于对实例特征进行线性变换， $\tanh$ 和 sigm （Sigmoid）分别是双曲正切和门控激活函数，用于引入非线性映射， $\odot$ 表示元素级乘法（Element-wise multiplication），用于使 $\tanh$ 的线性特征通过 sigm 的门控过滤。




图表 3 正样本包的注意力权重示例

3.5 双流多示例学习模型

双流多示例学习（Dual-stream Multiple Instance Learning, DSMIL）是由威斯康星大学麦迪逊分校团队^[14]提出的一种双流多实例学习网络。针对 WSI 中

正实例比例极低，即所谓的大海捞针问题。DSMIL 创新地提出了双流交互机制：一个流负责定位最关键的实例（Critical Instance），另一个流则基于与该关键实例的相似度来聚合全局信息。这种设计有效缓解了传统注意力机制在处理超大图像包时容易出现的权重平滑化问题。



图表 4 DSMIL 的 MIL 聚合器。最大池化分支通过池化实例得分来确定关键实例。这个聚合分支测量每个实例与关键实例之间的距离，并通过使用距离作为权重对实例嵌入进行求和来生成一个包嵌入。两个流的得分取平均值以生成最终得分。

在算法流程上，DSMIL 首先通过一个 Max-pooling 算子识别出预测得分最高的实例 h_m 作为锚点。随后，模型计算其他所有实例 h_i 与该关键实例之间的可训练距离度量 (Trainable Distance Measurement)，从而生成注意力权重 U ，公式如下：

$$U(h_i, h_m) = \exp(\langle q_i, q_m \rangle) / \sum_{k=0}^{N-1} \exp(\langle q_k, q_m \rangle), \quad (9)$$

其中 $U(h_i, h_m)$ 表示实例 h_i 相对于关键实例 h_m 的注意力得分， q_i 和 q_m 分别是实例 i 和关键实例 m 经过查询矩阵 (Query Matrix) 变换后的特征向量， $\langle \cdot, \cdot \rangle$ 表示向量内积，用于衡量实例间的相似性， N 是包内实例的总数。

最终的包预测分数由公式 15 得出：

$$c(B) = \frac{1}{2}(g_m + g_\beta), \quad (10)$$

其中 $c(B)$ 是包 B 的最终分类得分， g_m 代表基于最大值流 (Max-stream) 的局部预测分数， g_β 则代表基于注意力流 (Aggregator-stream) 的全局聚合分数。

此外，模型通过对比学习预训练特征，其损失函数如公式：

$$\mathcal{L} = -\log \left[\exp(\text{sim}(z_i, z_j)/\tau) / \sum_k \exp(\text{sim}(z_i, z_k)/\tau) \right], \quad (11)$$

其中 $\mathcal{L}$ 是对比损失， $\text{sim}(\cdot)$ 是余弦相似度函数， z_i 和 z_j 是一对正样本特征， τ 是温度超参数，用于控制相似度分布的平滑度。

图表 4 展示了 DSMIL 聚合器的详细结构。图中清晰地标绘了 Max Pooling 流与基于 Inner Product 的注意力流是如何并行运作并在最后通过 Fusion 层进行分数对冲的。该结构使得模型不仅能识别单个最强信号，还能捕捉到与主病灶相关的周边微环境信息。

3.6 结构化状态空间模型

结构化状态空间模型 (Structured State Space Models, S4MIL) 是由 CentraleSupélec 实验室^[31]提出应用于数字病理领域的先驱工作。由于 WSI 在高倍率下提取的序列长度可达数万级，传统的 Transformer 架构由于其自注意力机制的平方复杂度 ($O(N^2)$) 面临巨大的显存与计算挑战。S4MIL 模型通过线性常微分方程的离散化，实现了一种具备线性复杂度且拥有无限长上下文感知能力的序列建模方式。

S4MIL 的核心是将实例特征序列视为一个信号处理过程。其状态转换方程为：

$$x_t = \bar{A}x_{t-1} + Bu_t, \quad y_t = Cx_t + Du_t, \quad (12)$$


其中 u_t 是时间步 t 输入的实例特征， x_t 是隐藏状态向量，代表模型在 t 时刻对已观察序列的累积记忆， $\bar{A}$ 和 B 是离散化后的状态转移矩阵和输入矩阵，决定了记忆的更新逻辑， y_t 是 t 时刻的输出特征， C 是输出映射矩阵， D 则代表跳跃连接 (Skip connection) 参数。

为了并行训练，该系统被转化为卷积形式：

$$y = K * u + Du, \quad (13)$$

其中 y 是整个序列的输出， u 是输入序列特征， K 是 S4 卷积核，其由状态空间参数推导得出，能够覆盖无限长的上下文， $*$ 表示线性卷积操作。


该算法详细流程如图表 5 所示，该架构通过状态向量 x_t 实现了对数万个 *Patch* 的全局信息压缩，在维持 $O(N \log N)$ 效率的同时，极大增强了模型对大尺寸切片的建模深度。



图表 5 S4MIL 的流程概述。在第一步中，从一张全切片图像（WSI）的规则网格中提取补丁。这些补丁通过预训练的 ResNet50 进行嵌入，并由基于状态空间层的序列模型进行聚合。

3.7 基于知识图谱注意力机制的动态图表示学习模型

基于知识图谱注意力机制的动态图表示学习模型（Dynamic Graph Representation，WiKG）是由清华大学深圳国际研究生院团队^[29]提出的一种基于知识图谱注意力机制的动态图表示学习模型。WiKG 认为现有的 MIL 方法过于关注实例个体而忽略了实例间的空间与功能连接（如肿瘤细胞与周围免疫细胞的相互作用）。因此，WiKG 将 WSI 抽象为一个动态图（Dynamic Graph），通过定义节点间的头（Head）、尾（Tail）关系来动态构建图拓扑。



图表 6 WiKG 方法框架，包括图像块特征提取、基于首尾嵌入的动态边缘构建、图表示学习以及 WSI 的预测。

在方法论层面，WiKG 首先通过特征编码器将 patch 映射到特征空间，并动态计算实例间的余弦相似度。为了更新节点 h_i 的特征，WiKG 引入了知识感知注意力机制 (Knowledge-aware Attention)，其三元组信息的评分公式如下：

$$u(h_i, r_{ij}, t_j) = t_j^T \tanh(h_i + r_{ij}), \quad (14)$$

其中 u 是连接分值， h_i 代表头节点（中心实例）特征， t_j 代表尾节点（邻居实例）特征， r_{ij} 是节点 i 与 j 之间的有向关系嵌入（Relation embedding），用于编码实例间的相对特征交互， $\tanh$ 是非线性激活函数。

随后通过如下公式进行 Softmax 归一化，得到最终权重 π ：


$$\pi(h_i, r_{ij}, t_j) = \exp(u(h_i, r_{ij}, t_j)) / \sum_{j \in N_i} \exp(u(h_i, r_{ij}, t_j)), \quad (15)$$

其中 u 是连接分值， h_i 代表头节点（中心实例）特征， t_j 代表尾节点（邻居实例）特征， r_{ij} 是节点 i 与 j 之间的有向关系嵌入（Relation embedding），用于编码实例间的相对特征交互， π 是最终权重。

模型通过整合邻居信息更新节点状态，节点特征的更新则遵循公式：

$$h_i' = \sigma(W^1(h_i + h_{N(i)})) + \sigma(W^2(h_i \odot h_{N(i)})), \quad (16)$$

其中 h_i' 是更新后的节点特征， W_1 和 W_2 是可学习的权重矩阵， $h_{N(i)}$ 代表基于权重 π 聚合得到的邻居表征， σ 是激活函数（如 LeakyReLU）， $+$ 运算负责捕捉线性叠加特征，而 $\odot$ （逐元素乘法）则负责捕捉节点间的二阶交互信息。



图表 7 知识感知注意力机制的示意图，包括头向量、尾向量和边向量之间的聚合关系

这种双重交互机制，也就是加法聚合与逐元素乘法聚合，使得模型能够深入挖掘不同组织类型间的复杂依赖。图表 6 是 WiKG 的整体框架图，它展示

了从 Input WSI 开始，经过特征投影得到 Head/Tail 嵌入，再到 Edge Construction 阶段动态连接相似节点，最后通过叠加了注意力机制的图层进行特征演化的全过程。图表 7 放大展示了知识感知注意力的内部细节，解释了如何通过中间层对头尾节点进行语义融合，从而指导信息的精准传递。

3.8 基于自适应加权的集成学习策略

在 3.3 到 3.7 小节介绍了本文基于自适应加权的决策层集成方法选择集成的五个基础模型，接下来在本小节介绍下集成学习策略的详细实现。

3.8.1 基线池、参与方式与融合权重选择策略

集成对象固定为刚介绍完成的五类 MIL 基线，RRTMIL、AMIL、WiKG、DSMIL、S4MIL，与上述各节分别训练得到的任务与权重一一对应。集成模块本身不再学习新的特征变换，只在各基线已给出的 logits 或概率上做组合。参与融合的支路可以通过配置临时关掉其中若干路，例如出于算力或稳定性考虑，但不得五路全部关闭。被关掉的分支在融合权重视为 0，其余分支的权重在归一化意义上重新分配，仍参与融合的分支在本文记号里记为 $b=1, \dots, K$ ，通常 $K=5$ 。

融合权重 α^b 的确定遵循一条明确的优先链。若实验者直接给出各基线的非负相对权重，则归一化后即为 α^b ，此时不再强行做“只保留两路”的截断，以免覆盖人工意图。若没有显式权重，但提供了由队列 C-index 等写成的分支先验，既可以是人工表，也可以由系统在同癌种和同特征模式下按各基线历史最好表现自动填表，则先把先验转成非负向量，再归一化得到 α^b 。若上述两类信息都不存在，则对当前仍活跃的分支采用等权。在先验来自队列自动估计、且并未同时给出显式权重的前提下，融合投票会再做一个保守处理，只保留先验最高的两个分支，其余分支权重清零后重新归一化，以避免弱分支在概率平均里把高置信度摊薄，一旦改用显式权重，这一截断即取消。

训练阶段主要判断哪些基线进入融合、 α^b 取何分布。预测阶段在集成任务上还要判断与哪几条已训练任务对齐，这与 α^b 是两条线。蒸馏一侧在落库预测记录上按任务粒度统计队列 C-index，在当前癌种与特征模式下取排名第一

的基线任务，若该病例在这条任务上已有预测，就可直接复用其概率或风险，使本例输出不低于这条经队列验证的强单模。`tiebreak` 一侧仍基于同一套按任务排的 $C-index$ 表，取排名第一与第二的两条任务，在同一病例上得到 r^{best} 与 r^{second} ，供后文 λ 微调。若历史记录不足以支撑上述选择，则退回现场加载集成 `checkpoint`，对五路各做一次前向并按 `avg_prob` 融合。多折训练时，也可先将各折 `checkpoint` 上得到的支路 `logits` 做平均再送入融合，以减轻单次数据划分带来的方差，这只改变各支路 `logits` 的平滑方式，不改变 α^b 的语义。

3.8.2 决策层 `avg_prob` 融合与基础风险

对每一例、每一活跃分支 b ，分类头先给出 G 档离散风险上的 `logits` 向量 z^b 。将其转为分支上的类别分布，分支概率映射公式为：

$$p^b = \text{softmax}(z^b), \quad (17)$$

其中， z^b 表示第 b 个分支输出的 `logits` 向量， p^b 表示对应分支概率向量， b 为分支索引。

p^b 各分量非负且和为 1，与下游按档加权的口径一致。随后在概率域做凸组合，融合权重 α^b 由 3.8.1 所述规则给出，满足非负且归一，于是融合概率写为：

$$p^{fuse} = \sum_{b=1}^K \alpha^b p^b, \text{ 且 } \alpha^b \geq 0, \sum_{b=1}^K \alpha^b = 1, \quad (18)$$

其中， K 表示有效分支总数， α^b 表示第 b 个分支融合权重， p^{fuse} 表示融合后的概率输出。

这一步即 `avg_prob` 的核心，即对各支路 `softmax` 后的概率按 α^b 加权平均。若后续损失或接口仍希望落在 `logits` 域，可对 p^{fuse} 做稳定的对数回映射，即取极小正数 ε 防止真零，令：

$$z^{fuse} = \log(p^{fuse} + \varepsilon), \quad (19)$$

其中, p^{fuse} 表示融合后的概率输出, ε 是极小正数防止真零, z^{fuse} 是融合概率到 logits 的稳定对数映射

最后将亚风险分布压缩为标量期望档, 作为基础风险 r^{base} , 基础风险计算公式为:

$$r_{\text{base}} = \sum_{g=0 \rightarrow G-1} g \cdot p^{\text{fuse}}(g), \quad (20)$$

其中, G 表示离散风险分组总数, g 表示风险分组索引, $p^{\text{fuse}}(g)$ 表示融合概率在第 g 组的取值, r_{base} 表示基础融合风险分数。

3.8.3 蒸馏、双任务 tiebreak 与稳健门控

预测请求在集成任务上到达时, 优先在落库历史里查找队列 $C - index$ 最高的那条基线任务是否已为该病例给出预测, 若有则直接以其概率作为后续风险与展示的输入, 相当于用当前队列上实证最强的单模覆盖本例的初值, 使集成输出不低于这条已验证单模在该病例上的水平, 若无此类记录则加载集成 checkpoint, 对五路各做一次前向, 再得到 p^{fuse} 与 r^{base} 。这一安排给出的是工程意义上的下界保证, 而不是在集成头里再训练一套新参数。在已有蒸馏结果或已完成五路融合之后, 仍可在同一队列统计表上取出 $C - index$ 排名第一与第二的两条任务, 在同一病例上读取 r^{best} 与 r^{second} , 按下式做轻量微调, λ 在有限正数网格上搜索选取, 不反传更新各 MIL 主干参数。

$$r_{\lambda} = r^{\text{best}} + \lambda \cdot \text{sign}(r^{\text{second}} - r^{\text{best}}), \quad (21)$$

其中, r_{λ} 表示引入系数 λ 后该病例的风险分数, r^{best} 表示队列 $C - index$ 排名第一的训练任务在该病例上的风险, r^{second} 表示排名第二的训练任务在该病例上的风险, λ 表示微调幅度, λ_{cap} 表示 λ 允许取到的上界 (实现中取 0.10), $\text{sign}(\cdot)$ 表示符号函数, 对自变量 $r^{\text{second}} - r^{\text{best}}$ 而言, 差值为正时取 +1, 为负时取 -1, 为零时取 0。

采纳非零 λ 前需在验证子集与全队列上检验 Harrell C-index；记验证子集与全队列上的 C-index 泛函分别为 $C^{\text{val}}(\cdot)$ 与 $C^{\text{all}}(\cdot)$ ， $\lambda = 0$ 时基准风险为 r_0 ，则验证增益写为：

$$\Delta^{\text{val}}(\lambda) = C^{\text{val}}(r_\lambda) - C^{\text{val}}(r_0), \quad (22)$$

其中， $\Delta^{\text{val}}(\lambda)$ 表示在验证子集上，采用 r_λ 相对采用 r_0 的 $C - index$ 提升量， $C^{\text{val}}(r_\lambda)$ 表示以风险序列 r_λ 在验证子集上算得的 $C - index$ ， $C^{\text{val}}(r_0)$ 表示以基准风险 r_0 在验证子集上算得的 $C - index$ 。

回退判据为：

$$\Delta^{\text{val}}(\lambda) < \delta_{\min}, \quad C^{\text{all}}(r_\lambda) < C^{\text{all}}(r^0), \quad (23)$$

其中， $\delta_{\min}$ 表示验证集上可接受的最小 $C - index$ 增益阈值， $C^{\text{val}}(r_\lambda)$ 表示以风险序列 r_λ 在验证子集上算得的 $C - index$ ， $C^{\text{all}}(r_\lambda)$ 表示以 r_λ 在全队列上算得的 $C - index$ ， $C^{\text{all}}(r_0)$ 表示以 r_0 在全队列上算得的 $C - index$ ，两不等式任一成立即触发回退。成立时强制 $\lambda = 0$ 。时间切分按预测时间约 70%/30% 划分，用于在 λ 网格上比较 C^{val} ，若未触发公式，则输出 r_λ ，否则输出 r_0 对应风险。

3.9 模型训练

3.9.1 数据构建、样本规模与训练环境及划分协议

数据自 TCGA-LUSC 公开队列整理为病例级标注清单，共 469 张互不重复的全切片，每例含病例编号、切片编号、离散风险分层标签、删失指示与生存时间等元数据，并可与公开临床注释互查。实验管线按清单、划分、张量组织，清单与 $k = 4$ 套交叉验证划分表对齐后，为每一折分别构造训练、验证与测试子集，数据载入按袋级批量送入训练循环。病理图像经预提取后，20 $\times$ 与 10 $\times$ 两档倍率下的特征分别存入对应特征库，并与清单中的切片一一对应，主实验以袋级特征向量为网络输入。另设面向全切片联机读入与特征补全的读片与批组织子流程，供在线预测使用。上述清单共 469 条切片级记录，病例编号

与切片编号一一对应，折合 469 例。配套四套划分表各含 281 行，在与清单对齐后各自覆盖同一批 469 张切片，仅重新分配训练、验证与测试，不改变队列总数，折数 $k=4$ 与四套划分一一对应。

本文在 PyTorch 框架下完成上述 469 张切片的特征袋多实例学习训练，并完成决策级集成方法 EnsembleDecision 的训练与在线部署对接。运行环境包括 Python 3.10.20、PyTorch 2.11.0 与 Flask 3.1.3。本文实测以 CPU 训练与推理为主，若运行环境具备 GPU 且框架检测到加速设备可用，则训练与推理可自动启用 GPU，不改变算法结构，正文不绑定特定显卡型号与显存配置。

针对 TCGA-LUSC 生存弱监督设定，采用 $k=4$ 交叉验证，每折以训练集更新 MIL 主干，以验证集监控损失与 ROC AUC，以测试集参与折内评估。每折结束后保存模型检查点，供后续评估与任务快照读取。在同时满足 WSI 可及、生存与删失可对齐、双尺度 H5 完备的统计口径下，部署侧 Harrell C-index 汇总的有效病例数为 32 例。本文结论限定于 TCGA-LUSC、该 469 例清单与四折划分、 $k=4$ ，不将单次结果外推为大规模独立测试集的普适规律。

在上述划分与同一特征模式下，本文对 RRTMIL、AMIL、WiKG、DSMIL、S4MIL 五类代表性 MIL 结构分别进行了系统性训练，以覆盖不同的归纳偏置与聚合机制，并进一步启动 EnsembleDecision 任务，在加载五路基线权重的前提下完成集成前向、评估曲线生成与模型检查点落盘，使预测期能够结合 3.8 节所述的蒸馏、双任务 tiebreak 与门控回退策略开展队列级推理。各基线遵循各自网络类型对应的结构与损失接口，集成侧不新增可训练融合主干，从而保证单模训练与集成组合在方法边界上的清晰性。

表格 1 自上而下依次为数据与任务口径、特征输入形式、训练轮次与可选早停、优化与袋级批量及损失、正则与复现性、以及个别模型用到的结构超参。学习率用于控制参数更新步长。本文将学习率初始值取为 1×10^{-5} 。较高的学习率在小样本、袋级梯度噪声较大时易致损失震荡与验证指标不稳，过低则显著拉长达到可用验证性能所需的轮次。综合可观察收敛行为， 1×10^{-5} 在收敛速度与稳定性之间折中较好。批量大小表示每次更新所消耗的样本单元数。本系统在 MIL 管线中采用袋级组织，由深度学习框架的数据迭代器以每批一例装载完整特征袋及标签。该设置符合病理 MIL 常见做法，单张 WSI 对应实例数

量极大，增大袋级批量将显著抬高显存与工程复杂度，批量取 1 有利于在有限资源下稳定反传，并与本文 CPU 实测环境相匹配。

表格 1 模型训练参数

类别	参数	符号	取值或说明
数据与任务	癌种与任务设定	—	LUSC（肺鳞癌）
数据与任务	病例清单规模	—	469 张互不重复全切片
数据与任务	交叉验证划分	k	k = 4，四套划分表与清单对齐，每表 281 行，覆盖同一 469 张切片
特征输入	双尺度预提取特征	—	20× 档与 10× 档两路袋级特征，与清单中切片一一对应
训练协议	最大训练轮次	max_epochs	100，与四折叠加时总轮次约 4×100 或 4×120
训练协议	早停	Patience, stop_epoch	启用早停时：耐心 20 轮，最早自第 80 轮起可触发
优化	学习率	lr	1×10^{-5}
优化	优化器	opt	Adam
优化	权重衰减 (L2)	reg	1×10^{-5}
批次与损失	袋级批量大小	bs	1
正则化	随机失活	drop_out	默认启用
复现性	随机种子	seed	1
复现性	训练标签使用比例	label_frac	1.0
结构	文本原型数	prototype_number	16

最大训练轮次记为 max_epochs，表示外层 epoch 上限。本文默认 100，与 k = 4 叠加时，总轮次预算约为 4×100。若启用早停策略，则当验证监控量连续若干轮无改善且已超过预设最早生效轮次时可提前终止，以在充分拟合与避免无效长跑之间折中，未启用时则训练至 max_epochs 上限。交叉验证折数 k = 4，用于在 32 例可评队列这一小样本条件下获得多份可比较的折次轨迹。权重衰减取 1×10^{-5} ，与 Adam 联用，在自适应步长与轻微 L2 正则之间折中，抑制袋级过拟合。袋级分类损失以交叉熵为主，消融中可替换为支持向量机或 focal 形式以检验代理目标差异。随机失活默认开启。随机种子与训练标签使用

比例分别用于固定随机性与使用全量可用标签，便于复现。各 MIL 变体特有的结构超参数取统一默认，使各结构在可比默认配置下训练。各折结束后将模型状态写入按折次索引的检查点文件，保存节律与训练轮次对齐，供平台评估与快照读取。在模型训练过程中，优化器采用 Adam 算法，其结合一阶与二阶矩估计的自适应步长机制，能够减轻手工逐维调学习率的压力，并在非凸深度学习目标上广泛使用。

3.9.2 数据加载、特征形式与训练流程

在数据加载阶段，训练与验证样本自预提取的双尺度 H5 特征库中按顺序或随机策略遍历，是否加权依划分与配置而定。20× 与 10× 两档特征与 patch 提取倍率一致，模型前向同时消费两路张量以形成多尺度证据。特征载入后转为浮点类型并在 CPU 或 GPU 上统一计算。本文不在 patch 像素域以随机翻转等为主做增广，而依赖队列内病例异质性与 MIL 聚合结构提升表达，若特征缺失，可由全切片经在线特征提取补全后进入同一训练管线。训练主循环在每个 epoch 内依次执行袋级前向、损失回传、优化器步进与验证评估，验证阶段除记录 ROC AUC、分类误差与损失外，还可记录与生存排序一致的验证 C-index 等，用于分析分类代理目标与生存排序目标的对齐程度。集成任务在载入五路基线检查点后，可进入仅前向评估写盘的可选路径，以为部署侧提供与 3.8 节策略一致的 logits 与概率来源。通过上述环境与协议，本文获得了五类 MIL 基线在 TCGA-LUSC 子风险任务上的成套训练记录，以及集成方法 EnsembleDecision 在相同统计口径下的队列评估结果，具体的训练效果、性能评价指标与方法选择讨论将在下文给出。

3.9.3 评价指标

C-index 用于衡量病例级风险评分与生存结局之间的一致性。设可比较病例对集合由删失机制诱导，模型对病例 i 、 j 给出的风险为 r_i 、 r_j ，真实生存时间为 T_i 、 T_j ，删失指示为 δ_i 、 δ_j ，则在经典可比较对定义下，C-index 可理解为：在所有可被判定先后顺序的对上，模型排序与真实结局顺序一致的比例，并对

平局对赋予 0.5 权重，其取值在 0 与 1 之间，0.5 常作为随机排序的参考线，越接近 1 表示队列风险排序与真实可比较结局越一致。由于本文最终结论强调部署队列上的排序能力，因此将 C-index 作为论文主指标。

ROC AUC 与验证损失、分类误差、F1 等一同构成训练日志层指标，用于观察各 MIL 结构在不同折次上的收敛形态、过拟合风险与代理目标优化质量。验证 AUC 的峰值与队列 C-index 并不总是同向，原因在于折内验证划分与 32 例队列上的部署统计集合并不完全相同，且删失比例与可比较对的构造方式亦不相同。本文因此采用双层指标：训练日志层用于过程诊断，队列 C-index 层用于最终排序评价。

3.10 实验与结果

本文通过队列 C-index 与代表性任务的日志层 AUC、损失等对各模型进行了全面评估。各模型的详细预测结果如表格 2 所示，汇总各方法在部署随访队列上的 Harrell C-index 点估计，并给出与实验平台 PREDICTION 页一致的 bootstrap 95% 置信区间 ($B=400$)。评价对象为各模型当前展示规则下写入预测的病例级 riskScore 与临床生存标签在同一可比患者对定义上的一致性。表中相对推理耗时以单模前向为 1.00× 基准，集成行反映五路基线参与决策融合及策略判定后的近似倍数，便于评估离线部署成本。

表格 2 队列层主结果


方法	C-index	95% CI	相对推理耗时
RRTMIL	0.3541	0.2241–0.4721	1.00×
AMIL	0.4426	0.2912–0.6097	1.00×
WiKG	0.4164	0.2418–0.5838	1.00×
DSMIL	0.4131	0.2135–0.6040	1.00×
S4MIL	0.5180	0.3373–0.6975	1.00×
EnsembleDecision	0.5180	0.3373–0.6975	约 1.10×

表格 3 为训练过程层对照，对表格 2 所列各方法，各选取一条与论文实验记录可一一对应的代表性训练任务同源日志中摘录折内验证集/测试集上的 ROC AUC 与损失摘要。best / final val 分别表示训练过程中验证集上观测到的最优值与训练结束时刻的验证集取值，final test AUC 为训练末期的测试折 AUC。

表格 3 最优任务训练日志摘要

模型	best val AUC	final val AUC	final test AUC	best val loss	final val loss
RRTMIL	0.6538	0.598	0.518	1.3278	1.6551
AMIL	0.63	0.63	0.5097	1.3377	1.3392
WiKG	0.6389	0.5397	0.5391	1.3169	2.9378
DSMIL	0.6717	0.666	0.5339	1.3596	1.3596
S4MIL	0.6064	0.5404	0.4863	1.3372	1.3783
EnsembleDecision	0.601	0.5771	0.5308	0.5916	0.7465

如图表 8 所示，在同一癌种下，为每个模型自动选取其历史最优子任务并将六条曲线叠画在统一横轴上。纵轴为折内验证集损失，属于训练日志层代理指标，用于观察各 MIL 结构在弱监督子任务上的收敛形态与波动幅度，不能直接等同于表格 2 的队列 Harrell C-index。可见 EnsembleDecision（红线）在全程显著低于五路基线簇，曲线平滑、数值稳定，例如在约第 303 个 epoch 处，集成验证损失约 0.68，而各基线约在 1.37 附近，与表格 3 中集成任务 final val loss 明显低于单模的统计一致。五路基线中 WiKG（橙色虚线）在部分区间出现尖峰，提示图结构分支对超参与数据子集更敏感，亦从过程诊断角度支持多分支互补 和决策层稳健融合的工程动机。



图表 8 五路基线与 EnsembleDecision 的验证集 LOSS 曲线的最优任务对比

实验结果表明，五种 MIL 基线在队列 C-index 上呈现明显分化，其中 S4MIL 达到当前最优单模型水平（0.5180，95% CI 约 0.34–0.70）。EnsembleDecision 队列 C-index 亦为 0.5180、95% CI 与 S4MIL 相同，界面全局最高标签在并列时按实现规则落在集成行，不代表点估计严格大于 S4MIL。相对推理耗时约为单模型的 1.10×，来源于五路前向与决策层融合及策略判定，在离线评估与演示场景中通常可接受。表格 3 展示部分模型在验证 AUC 上具有较高峰值，但队列 C-index 未必同步领先，这一现象支持本文采用多分支融

合与稳健门控的动机，即通过互补证据与风险兜底改善整体排序稳定性，而非仅追逐单一折次的代理指标峰值。

从方法选择角度，与当前部署一致的可追溯集成预测链为首要目标，优先采用 EnsembleDecision 作为线上任务类型。若以当前主表队列 C-index 点估计为唯一排序指标且需最小算力，则 S4MIL 与集成任务在该快照下并列，可任选其一，并接受集成侧额外前向成本仅在需要集成策略时付出。若以训练日志 AUC 为次要参考，DSMIL 在表格 3 展示任务上呈现较高的验证 AUC 峰值，适于作为代理目标强的对照训练对象，AMIL 与 WiKG 在不同任务上呈现差异化的损失与 AUC 轨迹，适于作为分支多样性来源。上述判断仅适用于本章已声明的数据集、样本量与快照条件，更换癌种、扩大队列或更新划分后须重新训练并在新口径下重报 C-index。

第四章 系统设计与实现

4.1 系统需求分析

本系统面向肺癌风险预测，实现中以 TCGA-LUSC 为主，以全切片或预提取 patch 特征为输入的弱监督生存风险辅助分析场景。首先在数据与特征侧，系统应能按癌种维护双尺度（ $20\times/10\times$ ）H5 特征清单，完成特征文件的上传、列表查询与删除，并在需要时支持将光栅病理图（如 SVS 等常见格式经后端转换处理）入库及预览元数据登记，使后续模型与病例始终面对可追溯的文件标识。在临床与病例侧，系统应支持以随访表 CSV 批量导入或单条方式维护病例编号、生存时间、删失状态等关键字段，并支持将病例与特征文件建立绑定，既可直接关联已入库的双尺度 H5，也可在用户仅持有 WSI 时由后端在线抽取特征后再写入绑定关系，从而把随访标签与模型输入固定在同一个 caseId 之下。


在模型训练与评估侧，系统应覆盖多种 MIL 基线以及 EnsembleDecision 决策级集成训练，并允许配置学习率、交叉折数、训练轮数、早停及集成分支参与方式等超参。训练任务需具备入队、状态查询与日志落盘能力，以便评估模块解析 Loss、AUC 等曲线并形成摘要，同时支持多任务曲线对比以及 Kaplan-Meier 等扩展分析接口，支撑论文级的过程诊断叙述。在预测与队列评价侧，系统应能对用户选定的检查点任务执行病例级推理，将结果写入预测历史；并在与临床随访字段一致的口径下，对队列汇总 Harrell C-index 及可选的 bootstrap 95% CI，以便与第三章主表及平台展示规则逐字段核对。最后在运维与演示侧，系统应提供健康检查、运行配置的只读展示以及 API 基地址的可配置能力，从而降低实验室部署与答辩演示的环境切换成本。

在可部署性方面，后端以 Gunicorn + Flask 作为容器化入口，前端静态资源可独立构建并与反向代理组合，使浏览器仅暴露统一站点域名即可访问 /api。在可维护性方面，前后端职责分离，持久化以 JSON 清单、训练日志文件与按任务划分的运行产物目录为主，便于版本化备份与实验复现。在安全与资源方

面，上传体积受 MAX_UPLOAD_MB 等环境变量约束，训练以子进程方式执行以减轻对 API 工作线程的长时占用，对于批量预测、全量特征抽取等重计算接口，工程上仍以单任务串行或限流方式使用，避免演示机资源争用导致超时。

4.2 系统总体架构

本系统在逻辑上采用与大型医疗信息系统常见的终端、应用、能力、技术、数据五层纵向模型对齐的描述方式，上层回答用在什么场景，中层回答系统对外提供哪些能力，下层回答用哪些技术栈与哪些持久化载体落地。物理部署上仍为 B/S 结构，浏览器承载单页应用（SPA），经 HTTP(S) 访问 Flask 聚合的 /api 服务，训练与重计算推理在服务端以子进程和文件型数据湖方式组织，而非独立微服务集群，以降低系统的运维复杂度，系统架构图如图表 9 所示。



图表 9 系统整体架构图

终端层是系统服务的使用者与组织形态，本系统主要面向医院病理与肿瘤科、高校与科研院所、公共卫生与队列管理单位，以及个人研究者或小型联合门诊等形态。其中面向真实诊疗外推时须结合伦理与数据合规另行论证，实现以科研与演示为主。应用领域层刻画的是业务边界，在 TCGA-LUSC 等公开队列语境下完成弱监督生存风险排序，输入可以是病理全切片经离线抽取后的

H5 特征，也可以是平台内登记的等价数据对象，并服务于科研对比、消融与教学演示等目的。


业务能力层与产品顶栏模块对应，可概括为在 Data 中完成特征与数据集清单管理，在 Clinical 中完成随访与病例维护及 WSI/光栅入库后的在线抽特征，在 Training 中完成 MIL 与 EnsembleDecision 的训练排队与日志产出，在 Evaluation 中完成训练曲线、最优任务对比，在 Prediction 中完成单例或批量推理并汇总队列 Harrell C-index 与自助区间，在 Settings 中完成健康检查与 API 基地址等运行配置。技术实现层则落实为前端 React 18、React Router、Redux、MUI、Axios、Recharts、Vite 工程与后端 Flask、flask-cors、Gunicorn、gthread 服务进程，算法侧通过 main_LUSC.py 驱动 PyTorch 上的 RRTMIL、AMIL、WiKG、DSMIL、S4MIL、EnsembleDecision 等结构，数据交换以 JSON 清单、HDF5 与 multipart 上传为主。数据持久层将上述行为沉淀到 uploaded_features/。

4.3 系统流程

用户首先在浏览器中打开本系统单页应用，若训练与推理服务部署在与前端不同的主机或路径下，应先在设置页面填写并保存 API 根地址，由前端将此后所有请求统一指向该后端入口，并通过健康检查与配置只读区确认服务已连通、数据根路径正确。随后可进入总览页面查看数据集与特征规模、训练队列与健康状态，作为后续实验的入口界面，系统流程如图表 10 所示。

用户通过系统界面进入数据管理模块，在页面上选择癌种（例如肺鳞癌 LUSC）以及特征尺度（20× 与 10× 双尺度），将预提取的病理 patch 特征以 HDF5（H5）文件形式上传至服务器，系统为每个上传对象分配稳定标识并写入特征清单，便于后续按文件标识进行关联与删除。若用户手头是全切片或常见光栅病理切片格式而非现成 H5，亦可通过光栅入库入口将文件提交至后端登记，再由临床与特征关联流程触发在线特征抽取。上传或登记完成后，系统会维护与特征相关的元信息与一致性状态（例如特征维度是否齐全、双尺度文件是否成对出现），并在病例绑定后通过特征元数据接口供前端校验，避免有随访、无特征或仅单尺度等不匹配情况进入训练与预测环节。

用户随后在临床模块中导入随访表或逐条录入病例编号、生存时间、删失指示等字段，使系统内病例对象与队列统计所需临床信息一致。接着将每个病例与已在库中的 20×、10× 特征文件建立绑定，若用户仅上传全切片图像，则可在关联特征流程中选择快速预览或正式抽取等策略，由服务器在后台完成特征计算与落盘，界面以进度条等形式提示长时任务直至结束。用户还可请求缩略预览以肉眼核对切片区域，系统则在校验通过后将病例标记为具备完整推理条件的状态。



图表 10 系统流程图

当数据与随访准备就绪后，用户进入训练页面，从下拉菜单中选择多实例学习模型类型（如 RRTMIL、AMIL、WiKG、DSMIL、S4MIL 等单模型，或

EnsembleDecision 决策级集成)，若选择集成模式，用户可在界面上指定参与决策融合的基线分支、决策层融合方式等选项，并填写学习率、交叉验证折数、最大训练轮数、随机种子等超参数。系统根据用户提交的配置生成训练任务并加入服务端队列，在资源互斥策略下，训练过程在服务器端以子进程方式执行，运行日志持续写入磁盘，检查点与运行产物按任务编号归档。训练进行过程中，用户可在训练页查看日志片段与任务状态，必要时中止排队或运行中的任务，任务结束后，用户即可在模型评估模块中选中该任务查看曲线与摘要。

用户进入模型评估页面后，可在任务列表或运行枚举中选择已完成的训练任务，系统在界面上绘制验证集损失、验证集与测试集 ROC AUC 等随训练进程变化的曲线，并支持在最优任务对比等视图中将多条模型曲线叠置，以便直观比较不同结构或不同随机种子下的收敛形态。系统还可根据产品规则解析最佳任务标识。若用户需要进一步从生存资料角度进行可视化对比，可在评估模块中调用平台提供的扩展分析入口，在同一随访口径下查看分组生存曲线，作为对排序指标的过程性补充。

用户随后进入预测页面，在任务下拉框中选择已结束且具备可用检查点的训练任务，在病例下拉框中选择待评估病例，点击执行预测，系统在服务器端加载对应权重并完成前向计算，对集成任务则按既定管线汇总多分支证据并输出病例级风险分数。预测结果可在界面上以风险条、分层标签等形式展示，用户若勾选写入历史，系统将把该次预测追加保存，便于后续审计与复现。对于希望跳过预先绑定特征步骤的演示场景，用户亦可使用自上传图像直接预测类入口，由服务器先完成特征侧处理再返回风险分数，其主流程仍以先完成临床与特征闭环、再按病例推理为推荐路径。

在完成多次预测并形成预测历史后，用户可在预测页查看各模型队列 Harrell C-index 汇总表。系统在后台将各模型类型下最新一次写入的病例风险与临床随访字段按可比患者规则对齐，计算一致性指数，并可按需在请求中指定自助法次数以给出 95% 置信区间。用户据此可对比不同模型在同一随访队列上的排序能力。

4.4 系统前端设计与实现

本系统的前端设计采用当前主流的现代化 Web 单页应用技术栈，以 React 18 为视图内核，结合 Vite 构建工具、Material UI (MUI) 组件库与 Axios 异步请求库，并辅以 Recharts 完成训练与评估曲线的可视化，整体构成具有清晰信息层级与即时反馈特性的病理生存风险分析平台。全局状态由 Redux 托管，主题与明暗基线由 MUI ThemeProvider 与 CssBaseline 统一收敛，使各业务页在字体、间距与色彩上保持同一套视觉语言。与早期大量依赖 jQuery 手动操作 DOM 的页面不同，本系统通过声明式组件与虚拟 DOM 差分更新降低界面抖动风险，数据获取与提交一律走 Promise 化的 HTTP 调用，由前端在路由切换后按需拉取 JSON 并驱动界面重绘，从而在体验上接近无整页刷新的流畅切换效果。

系统入口设计为顶部粘性导航栏加内容区容器的经典导览结构：顶栏左侧展示系统中文标题，右侧以按钮组形式排列 Dashboard、Data、Training、Evaluation、Clinical、Prediction、Settings 功能入口，当前路由对应的按钮以描边高亮显示，用户一眼即可识别所处模块。首屏 Dashboard 采用分区卡片布局，以不同顶边色带与浅色底区分健康与配置、数据与特征、训练与队列等总览区块，各卡片内聚合图标、标题、摘要数字与快捷操作，使用户尚未深入子页即可把握系统运行态势。当用户将鼠标悬停在部分卡片或列表行上时，组件样式中预设的过渡（transition）会触发阴影加深与轻微浮起感，在不过分干扰阅读的前提下提供可点击或可展开的暗示。在训练、评估等表单密集页面，MUI Tooltip 与 Alert 提示为学习率、集成分支、任务状态等关键控件补充短说明，降低首次使用成本。

用户点击顶栏任一功能入口后，React Router 在浏览器端完成路由切换，内容区在不重新加载整页 HTML 的前提下替换为对应业务组件，延续了导览栏所建立的交互范式，各子页内部的列表刷新、日志尾部拉取、曲线数据加载等均由 Axios 向后端/api 前缀发起异步请求，并在等待期间以 CircularProgress、LinearProgress 等组件给出进度反馈，长任务结束或异常时由轻量的 Toast 或行内 Alert 提示结果。在训练板块中，用户可在同一屏内完成模型类型选择、超参数填写、集成策略勾选与训练启停，减少为配置实验而在多窗口之间来回

跳转的次数，在模型评估板块中，Recharts 折线图支持图例开关、悬停提示框与多曲线叠画，便于对照不同任务的 Loss、AUC 形态。在预测板块中，病例风险以条带、徽标与表格行综合呈现，并与队列层 C-index 汇总表同页联动阅读，使单次推理结果与队列层排序结论在视觉动线上自然衔接。

4.5 系统后端设计与实现

本系统的后端采用 Python Flask 构建单体聚合式 REST 服务，在 `api_server.py` 中以应用工厂 `create_app()` 统一注册路由、跨域策略与上传体积限制，启用 `flask-cors` 以便浏览器跨源访问，通过 `MAX_CONTENT_LENGTH` 等配置约束单次上传文件大小，避免异常大包占满磁盘。所有对外接口均挂载在 `/api` 路径前缀之下，与前端 Axios 的默认拼接规则一致。服务既可由 `python api_server.py` 直接拉起用于开发调试，也可在容器内由 Gunicorn 以 `api_server:app` 为入口、配合 `gthread` 工作模式监听 8000 端口，从而在部署环境中获得更稳定的进程级并发能力。

```
=> [internal] load local bake definitions          0.0s
=> reading from stdin 585B                        0.0s
=> [internal] load build definition from Dockerfile 0.0s
=> transferring dockerfile: 588B                   0.0s
=> [internal] load metadata for docker.io/library/vila-mil-backend-base:local 0.2s
=> [internal] load .dockerignore                   0.0s
=> transferring context: 483B                      0.0s
=> [1/5] FROM docker.io/library/vila-mil-backend-base:local@sha256:3a18f8038f776b84c06b6 0.0s
=> resolve docker.io/library/vila-mil-backend-base:local@sha256:3a18f8038f776b84c06b6 0.0s
=> [internal] load build context                   0.2s
=> transferring context: 223.72kB                  0.2s
=> CACHED [2/5] WORKDIR /app                       0.0s
=> CACHED [3/5] COPY deploy/requirements-api-app.txt /tmp/requirements-api-app.txt 0.0s
=> CACHED [4/5] RUN pip install -r /tmp/requirements-api-app.txt 0.0s
=> CACHED [5/5] COPY . /app                       0.0s
=> exporting to image                             0.0s
=> exporting layers                               0.0s
=> exporting manifest sha256:90e3431e72daacdd8dcdd6f031e524eb6f72464d98c206be7c4e9bbb 0.0s
=> exporting config sha256:0b954dc1c635ee310bfa6d20ad0e560434ad51c56a2e7b91037ffe3ed3 0.0s
=> exporting attestation manifest sha256:8f14221fcb5d3be6de71fc0e8f4129f27e24eef021fb 0.0s
=> exporting manifest list sha256:7d156176971af2802c47d82553d1adf6bdf6b41af3dbbaf807 0.0s
=> naming to docker.io/library/vila-mil-backend:latest 0.0s
=> resolving provenance for metadata file          0.0s
[+] Running 4/4
✓ vila-mil-backend Built 0.0s
✓ Container vila-mil-backend Healthy 6.6s
✓ Container vila-mil-frontend Healthy 6.1s
✓ Container vila-mil-gateway Running 0.0s
```


图表 11 后端监听请求及部分日志输出

在业务编排上，后端将轻量查询与重计算解耦，列表类、配置类、JSON 读写类请求在同进程内快速返回。模型训练则通过创建子进程调用 `main_LUSC.py` 完成，标准输出重定向至 `api_training_logs/<taskId>.log`，任务元数据写入 `uploaded_features/tasks.json`，检查点与运行产物落入 `result/api_runs/<taskId>/`，由后台调度线程在队列语义下依次拉起，并在进程异

常退出或服务重启时将孤儿任务回退为可再次调度状态。训练相关的 /training/start、stop、status、history、queue、best、log 等接口覆盖从提交到收尾的全生命周期。数据与临床侧则通过 /data/*、/clinical/* 维护特征清单、病例随访与特征绑定。评估模块以 /evaluation/curves/<taskId> 解析日志曲线，并可选 /evaluation/km 提供生存曲线分析入口。预测模块以 /predict 系列完成单例、批量与光栅快捷推理，以 /predictions 在服务器端聚合最新 riskScore 与 cases.json 随访字段，按 Harrell 规则计算队列 C-index 与 95% CI。EnsembleDecision 推理路径在服务端按五路基线与决策融合配置组装前向结果，写入 predictions.json 时附带 PREDICT_PROTOCOL_ID 等协议字段，便于实验记录。

4.6 系统界面展示


到展示了系统功能界面入口介绍了数据集、训练、随诊、预测、设置等功能。




图表 12 系统总览界面，展示服务状态、最近训练与预测



图表 13 点击任一训练任务展开详情



图表 14 数据管理界面, 对 h5 特征文件进行增删改查



图表 15 模型训练界面

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA **TRAINING** EVALUATION CLINICAL PREDICTION SETTINGS

Start Training

Cancer
LUSC (肺鳞状细胞癌)

Model
EnsembleDecision (决策级...)

maxEpochs
3

learningRate
0.00001

kFolds
4

weightDecay
0.00001

repeat
1

seed
1

交叉验证折数 (k) L2 权重衰减 (l2-reg) 重复训练次数 baseSeed (repeat 时递增)

☐ 早停 (early_stopping, 按验证集 val_error)

基线子集 (ensembleExclude)
勾选 = 该路参与决策融合; 取消勾选 = 排除该路基线 logits.

☒ RRTMIL ☒ AMIL ☒ WIKG ☒ DSML ☒ S4MIL

快速子集

当前将提交: 启用=[RRTMIL, AMIL, WIKG, DSML, S4MIL]; --ensemble_exclude (空)

EnsembleDecision 为决策级 (后期) 融合: 每路走完各自 MIL 并给出判断, 再在 logits/概率应用固定规则合并 (投票或加权), 不训练融合层。任务仅用于写出带融合配置的 checkpoint 并验证/测试; 五路基线须已训练, 后续按折从 best_models.json / tasks.json 解析五路 checkpoint,

当前仅保留一种简单融合: avg_prob (各基线输出概率逐类平均)。例如 A=80%, B=70%, 融合即 75%。

决策融合 decisionFusion
简单概率均值 (avg_prob)

分支先验 (可选, 用于 weighted 固定权重)

图表 16 集成方法训练界面

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING **EVALUATION** CLINICAL PREDICTION SETTINGS

模型评估 (训练曲线)

后续从训练日志解析 Loss, AUC (与任务列表中的 clndex 同源: 分类下为 Val Set 的 auc)、F1、error 等; 生存任务若日志格式不同, 部分字段可能为「-」。

选择训练任务 (Run)

刷新列表 全部刷新

最佳 手动 RRTMIL - LUSC

当前曲线任务: 训练参数与融合选项

taskid 9b043b7e-16a7-4c1e-a528-89b15b93cb14 数据来自 /api/training/status (与 Dashboard 任务详情一致)

癌种	模型	maxEpochs	learningRate
LUSC	transformer	100	0.000005
kFolds	weightDecay	seed	earlyStopping
4	0.0001	11	false

bestTaskId: 9b043b7e-16a7-4c1e-a528-89b15b93cb14; bestValLoss: 1.3278; 最后刷新: 2026/5/6 02:08:52

训练曲线

同一任务可能包含 k-fold: 横轴为全局 epoch (fold × maxEpochs + epoch)。AUC 与平台 clndex 一致 (分类任务来自 Val Set 的 auc)。

Y 轴自适应 Y 轴从 0 展开明细 导出 CSV

摘要指标 (全日志解析)


图表 17 模型评估界面-选择模型与训练任务



图表 18 模型评估界面-任务训练曲线展示-训练集/验证集 loss、AUC

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION



图表 19 模型评估界面-任务训练曲线展示-训练集/验证集 F1、error

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION SETTING



图表 20 模型评估界面-最优任务曲线对比，可筛选模型比对每个模型最优一次训练任务的训练集 loss、验证集 loss、验证集 AUC

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION SETTINGS

对比任务: RRTMIL(9b043b7e...); AMIL(0dd13630...); WIKG(84ee82d7...); DSMIL(28c4a2f7...); S4MIL(87cc0c8c...); EnsembleDecision(67a0f441...)
注: EnsembleDecision 为 fold 级评估点 (非逐 epoch 训练), 已启用跨空值连线展示过程趋势。

最优 5 基模型 + EnsembleDecision 指标总览

展示当前癌种下 5 个基模型 + EnsembleDecision 的最佳任务关键指标

模型	bestTaskId	bestValLoss	finalValAUC	bestValF1	finalValF1	finalTestAUC	epochCount
RRTMIL	9b043b7e-16a...	1.3278	0.5980	0.3886	0.3077	0.5180	400
AMIL	0dd13630-8ae...	1.3377	0.6300	0.3117	0.2419	0.5097	480
WIKG	84ee82d7-0c3...	1.3169	0.5397	0.4179	0.2605	0.5391	400
DSMIL	28c4a2f7-de0...	1.3596	0.6660	0.2540	0.1369	0.5339	400
S4MIL	87cc0c8c-ce7...	1.3372	0.5404	0.3361	0.2830	0.4863	400
EnsembleDecision	67a0f441-bdc...	0.6057	0.5997	0.2915	0.2066	0.4909	400

注: EnsembleDecision 与单模型任务相同, 由该任务训练日志解析曲线与指标; 若日志字段缺失, 部分列可能显示为「-」。

图表 21 模型评估界面-每个模型最优一次训练任务的指标总览

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION SETTINGS

Clinical

左栏维护随访与病例；右栏为当前选中病例准备推理用的双尺度特征。两栏共用同一「当前病例」。

随访

病例与生存数据

导入 CSV 或手动新增 caseld，再编辑 time / status（用于随访与部分分析）。

批量导入

CSV 需含 case_id, time, status (1=事件, 0=删失)；其余列进入 clinicalVars。

[选择 CSV](#) [导入](#)

病例操作

A. 新增病例

[新增并选中](#)

B. 已有病例管理（选择 / 修改 / 删除）

当前病例
TCGA_BATCH_TCGA-18-3419-11A-01-TS1

time
2

status
0 删失

随访时间

[保存随访](#) [删除病例](#)

共 32 个病例

特征与推理

绑定 MIL 所需双尺度 H5

推理只读 20x 与 10x 特征，可选：在数据管理页已上传的 H5，或在此上传 WSI 由后端生成特征。

操作对象 [TCGA_BATCH_TCGA-18-3419-11A-01-TS1](#)

方式

[已有 H5 文件](#) [从 WSI 生成](#)

物种
LUSC

20x 特征

10x 特征

[保存关联](#)

当前病例特征状态

来源：图像派生

20x: fd2a51c5-9ce2-4aee-958f-02f07cb0c11a

10x: bb9328da-9886-4047-b7e9-742f8435e923

图像文件名: TCGA-18-3419-11A-01-TS1.fe0b9f2c-d38d-487a-a67d-b2ab021f42ee.svs

图表 22 病例管理界面-对病例进行增删改查，可从 csv 文件一键导入或单个新增，可在右侧上传 WSI 图像解析成 h5 特征或直接上传 h5 特征文件

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION SETTINGS

新 caseld [新增并选中](#)

B. 已有病例管理（选择 / 修改 / 删除）

当前病例
TCGA_BATCH_TCGA-18-3419-11A-01-TS1

time
2

status
0 删失

随访时间

[保存随访](#) [删除病例](#)

共 32 个病例

10x 特征

[保存关联](#)

当前病例特征状态

来源：图像派生

20x: fd2a51c5-9ce2-4aee-958f-02f07cb0c11a

10x: bb9328da-9886-4047-b7e9-742f8435e923

图像文件名: TCGA-18-3419-11A-01-TS1.fe0b9f2c-d38d-487a-a67d-b2ab021f42ee.svs

已绑定病例图片预览

TCGA_BATCH_TCGA-18-3419-11A-01-TS1（已绑定预览）

已生成特征，预览保留；选择新图像可替换

图像预览（框内可拖动滚动：拖曳滑块或 Ctrl+滚 + 滚轮细滚）

100%

图表 23 病例管理界面-已上传病理图像预览

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION CLINICAL PREDICTION SETTINGS

Prediction

选择训练任务与病例后点击 Predict；也可使用「一键预测 N 个病例」对 Clinical 中已绑定双尺度特征、且与当前任务维度匹配的全部病例批量写入预测历史（N 随任务与特征自动计算）。

历史预测队列 · 生存 C-index（按模型）

当前所选任务（与下方任务选择一致）

taskid: 0d013630-8aef-41e7-b351-15a43cc7288d · LUSC AMIL Training

队列 C-index: **0.4426** (0.2912-0.6097) · 可用病例 n=32, 可比患者对=305

模型类型	代表任务 taskid	队列 C-index	95% CI	可用病例 n	可比患者对
AMIL	0d013630-288d LUSC AMIL Training	0.4426	0.2912-0.6097	32	305
DSMIL	28c4a2f7-b13c LUSC DSMIL Training	0.4131	0.2135-0.6040	32	305
EnsembleDecision	67a8f441-cafa LUSC EnsembleDecision Training	0.5180	0.3373-0.6975	32	305
RRTMIL	90a43b7e-cb14 LUSC RRTMIL Training	0.3541	0.2241-0.4721	32	305
S4MIL	87cc8c8c-931e LUSC S4MIL Training	0.5180	0.3373-0.6975	32	305
WIKG	84ee82d7-2702 LUSC WIKG Training	0.4164	0.2418-0.5838	32	305

图表 24 预测界面-历史预测队列

1) 选择输入

Case
TCGA_BATCH_TCGA-18-3419-01A-01-BS1

① 当前 case 特征维度: 20x=512, 10x=512, 拼接=1024

最佳 手动 Model S4MIL — LUSC

REFRESH PREDICT 一键预测 32 个病例

仅显示「已完成且存在 checkpoint」的任务。单次 Predict 使用当前下拉框中的病例；批量按钮会对列表中全部「已登记 20x+10x 且与当前任务维度一致」的病例调用 /predict/batch (例如 31 个病例时会显示「一键预测 31 个病例」)。
当前最佳 taskid: 87cc8c8c-ce7c-4ad7-9d9d-02ff988c931e (bestValLoss: 1.3372)

2) 风险评分与分层


Risk score (0~3) 三档风险分层 Model
1.9775 中风险 S4MIL

随访摘要
time: 1; status: 1; features: 20x true / 10x true

① 当前模型推理仅使用已提取的双尺度 patch 特征 (H5)。若仅有原始图像, 请先在离线流程完成组织分割与特征提取并生成 H5, 或使用本平台的病理图像关联流程生成特征。

3) 概率分布可视化

图表 25 预测界面-单个病例预测结果-风险评分与分层



图表 26 预测界面-单个病例预测结果-概率可视化

基于病理图像的肺癌生存风险预测系统

DASHBOARD DATA TRAINING EVALUATION

批量预测完成: 成功 32, 失败 0 (共 32 条)

模型类型	代表任务 taskid	队列 C-index	95% CI	成功数	失败数
AMIL	0dd13638-288d LUSC AMIL Training	0.4426	0.2912-0.6097	32	305
DSMIL	28c4a2f7-b13c LUSC DSMIL Training	0.4131	0.2135-0.6040	32	305
EnsembleDecision	67a9f441-cafa LUSC EnsembleDecision Training	0.5100	0.3373-0.6975	32	305
RRTMIL	9b043b7e-cb14 LUSC RRTMIL Training	0.3541	0.2241-0.4721	32	305
S4MIL	87cc8c8c-931e LUSC S4MIL Training	0.5100	0.3373-0.6975	32	305
WIKG	84ee82d7-2782 LUSC WIKG Training	0.4164	0.2418-0.5838	32	305

1) 选择输入

Case
TCGA_BATCH_TCGA-18-3419-01A-01-BS1

① 当前 case 特征维度: 20x=512, 10x=512, 拼接=1024

最佳 手动 Model S4MIL — LUSC

REFRESH PREDICT 一键预测 32 个病例

仅显示「已完成且存在 checkpoint」的任务。单次 Predict 使用当前下拉框中的病例；批量按钮会对列表中全部「已登记 20x+10x 且与当前任务维度一致」的病例调用 /predict/batch (例如 31 个病例时会显示「一键预测 31 个病例」)。
当前最佳 taskid: 87cc8c8c-ce7c-4ad7-9d9d-02ff988c931e (bestValLoss: 1.3372)

图表 27 预测界面-一键预测所有病例-历史预测队列随之更新

设置

配置 API 地址，查看平台说明与服务器路径；更换域名或排查接口时可优先检查本页。

接口与部署

通常保持 /api (Nginx 反代)。

API BaseURL

/api

示例: /api 或 http://121.41.39.63/api

保存

重新读取服务器路径

① 如果你使用 Nginx (推荐)，前端访问域名即可，接口保持 /api。
若前端不走同域名 (跨域)，可以把 BaseURL 改成带域名的完整地址。

平台介绍

本系统是一个以多模型集成 (EnsembleDecision) 为核心的病理生存风险预测平台：先训练多路 MIL 基线 (如 RRTMIL、AMIL、WIKG、DSMIL、S4MIL)，再在统一口径下进行集成推理与对比评估。推理输入采用双尺度 (20x / 10x) H5；Clinical 支持由 WSI 在线生成特征，结果用于科研流程验证。

当前版本提供：

- 集成核心：EnsembleDecision (当前以概率融合为主)，支持与 5 个基线模型同屏对比
- 训练与评估：多模型 k-fold、日志与 checkpoint 管理；曲线面板支持基线集成过程可视化
- 集成展示：最优任务对比中可同时查看验证 Loss / 训练 Loss / 验证 AUC 的统一曲线
- Clinical：随访管理 + 特征绑定分栏设计，支持“从 WSI 生成” (快速预览=低采样近似，正式预测=TRIDENT 全量)
- Prediction：按病例读取已绑定特征进行推理，展示风险得分、分层结果与概率分布
- 兼容性保护：任务下拉自动执行特征维度校验，不匹配任务置灰提示

使用前请知悉：

图表 28 设置界面-修改服务器路径、平台介绍

使用方法 (推荐流程)

- 1 Data Management: 按癌种上传 20x 与 10x 特征 H5，供病例关联或直接预测使用。
- 2 Clinical: 页面分左右两栏——左栏「随访」导入 CSV 或维护 caseld、time、status；右栏「特征与推理」为当前选中病例绑定双尺度 H5，或上传病理图像由后端在线生成特征 (上传成功后可保留预览并缩放查看细节)。
- 3 Training: 选择模型与超参启动训练；同一时间仅允许一个训练任务；支持资源预检与空闲超时自动停止。
- 4 Model Evaluation: 选择已完成的 run 查看训练曲线与摘要；可按需做 KM 与 log-rank 分析。
- 5 Prediction: 仅支持按病例 (cases.json) 推理，使用 Clinical 中该病例已绑定的 20x/10x 特征。Task 下拉仅列出已结束且含 checkpoint 的任务，并按当前病例特征维度做兼容性校验 (不匹配任务置灰提示)。
- 6 Settings (本页)：配置 API BaseURL；查看下方服务器路径与后端说明。

流程测试样例 (V^o^)-)

虚构数据，仅供走通 Clinical / Prediction 等流程，不代表真实病例。

下载到本地后，按右侧「建议操作」在对应页面导入或上传。双尺度 H5 体积较大，未在此打包；请使用 Data Management 上传自有特征，或使用已完成训练产生的特征。

随访 CSV

含 case_id、time、status (0=缺失, 1=事件)；列 group_label 会进入 clinicalVars，可用于 Clinical 左栏「导入」。

下载 SAMPLE_CLINICAL_FOLLOWUP.CSV

图表 29 设置界面-使用方法介绍

病理示例 WSI (SVS)

TCGA-LUSC 示例切片 (svs)，用于 Clinical 右栏「从 WSI 生成」联调与快速/正式模式演示。

下载 SAMPLE_TCGA_LUSC_DEMO.SVS

建议操作顺序 (可变速)

- ① 下载 CSV → Clinical 左栏导入 → 选中或新建与 CSV 一致的 caseld (如 DEMO_FLOW_001)。
- ② 下载 SVS → Clinical 右栏选「从 WSI 生成」→ 上传 SVS → 选择「快速预览」或「正式预测」。
- ③ 打开 Prediction → 按病例选择该 caseld，并选择已有 checkpoint 的 Task → Predict。

服务器路径 (只读)

来自后端 /api/config，用于排错与写论文/任务书说明。

```
baseDir: /app
ensembleDecisionTraining: [Object Object]
featuresDir20: /app/features/20
nginxStaticRootSuggested: /vila-mil-frontend/dist
timeZoneUi: UTC+8

dataRoot: /app/uploaded_features
featuresDir10: /app/features/10
logDir: /app/api_training_logs
resultsApiRunsDir: /app/result/api_runs
uploadedFeaturesRoot: /app/uploaded_features
```

① 常规推理依赖双尺度 patch 特征 (H5)。
POST /api/predict/from-raster: PNG/JPEG → 在线 ResNet50 双尺度 H5 (演示用，与 TCGA 特征分布可能不一致)。

图表 30 设置界面-服务器路径展示

第五章 总结与展望

5.1 总结

本文立足于肺癌临床预后评估的实际需求，针对病理全切片图像处理中的异质性与标注稀疏问题，完成了一套从多算法集成到工程系统落地的研究工作。在算法层面，本文系统地探讨了五种多实例学习基线模型的特性，通过设计决策级集成方法，成功地将不同架构的预测能力进行优势互补。该方法通过引入自适应加权与稳健回退机制，在不增加主干模型训练负担的前提下，显著提升了生存风险预测的准确度与系统鲁棒性，解决了单一模型对特定数据分布过度敏感的局限。

在工程实践层面，本文开发了一套功能完备的生存风险预测平台，通过 Flask、Gunicorn 与 React 的协同工作，实现了病例管理、特征预取、异步训练及性能评估的自动化流程。系统的成功构建不仅证明了集成算法在临床预测中的有效性，圆满达成了研究预期目标。

5.2 展望

尽管本文在肺癌风险分层预测方面取得了一定进展，但仍有诸多方向值得未来进一步探索。首先是在数据的泛化验证上，目前的研究主要基于 TCGA 公开数据集，未来需引入更多来自国内医疗机构的多中心数据进行外部校验，以测试系统在不同制片与扫描条件下的稳健性。其次，在多模态融合方面，目前系统主要依赖病理图像的形态学特征。后续可尝试将切片的微观特征与患者的临床病史、基因组学等多源数据进行深度耦合，构建更为立体的生存预后模型。最后，在临床决策的深度辅助上，未来计划进一步优化热力图可视化与诊断逻辑的关联，使系统不仅能给出风险分值，更能提供符合病理学逻辑的归因解释，从而更有效地赋能临床精准医疗。

致谢

参考文献

- [1] Zhu X, Yao J, Zhu F, et al. Wsisa: Making survival prediction from whole slide histopathological images[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7234-7242.
- [2] Yao J, Zhu X, Jonnagaddala J, et al. Whole slide images based cancer survival prediction using attention guided deep multiple instance learning networks[J]. Medical image analysis, 2020, 65: 101789.
- [3] Chen R J, Lu M Y, Shaban M, et al. Whole slide images are 2d point clouds: Context-aware survival prediction using patch-based graph convolutional networks[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer International Publishing, 2021: 339-349.
- [4] Chen T, Wen J, Shen X, et al. Whole slide image based deep learning refines prognosis and therapeutic response evaluation in lung adenocarcinoma[J]. NPJ Digital Medicine, 2025, 8(1): 69.
- [5] Shao Z, Bian H, Chen Y, et al. Transmil: Transformer based correlated multiple instance learning for whole slide image classification[J]. Advances in neural information processing systems, 2021, 34: 2136-2147.
- [6] Yan R, Lv Z, Yang Z, et al. Sparse and hierarchical transformer for survival analysis on whole slide images[J]. IEEE Journal of Biomedical and Health Informatics, 2023, 28(1): 7-18.
- [7] Li J, Liu J, Kuang H, et al. MiCo: Multiple Instance Learning with Context-Aware Clustering for Whole Slide Image Analysis[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2025: 376-385.
- [8] Han X, Zhou H, Tian Z, et al. Inter-intra hypergraph computation for survival prediction on whole slide images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025.

- [9] Shao Z, Chen Y, Bian H, et al. HvtSurv: Hierarchical vision transformer for patient-level survival prediction from whole slide image[C]//Proceedings of the AAAI conference on artificial intelligence. 2023, 37(2): 2209-2217.
- [10] Zhang Y, Yang Z, Chen R, et al. Histopathology images-based deep learning prediction of prognosis and therapeutic response in small cell lung cancer[J]. NPJ digital medicine, 2024, 7(1): 15.
- [11] Shou Y, Cao X, Yan P, et al. Graph domain adaptation with dual-branch encoder and two-level alignment for whole slide image-based survival prediction[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 19925-19935.
- [12] Tang W, Zhou F, Huang S, et al. Feature re-embedding: Towards foundation model-level performance in computational pathology[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 11343-11352.
- [13] Xiang J, Zhang J. Exploring low-rank property in multiple instance learning for whole slide image classification[C]//The Eleventh International Conference on Learning Representations. 2023.
- [14] Li B, Li Y, Eliceiri K W. Dual-stream multiple instance learning network for whole slide image classification with self-supervised contrastive learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14318-14328.
- [15] Zhang H, Meng Y, Zhao Y, et al. Dtf-d-mil: Double-tier feature distillation multiple instance learning for histopathology whole slide image classification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 18802-18812.
- [16] Liu P, Ji L, Ye F, et al. Advmil: Adversarial multiple instance learning for the survival analysis on whole-slide images[J]. Medical Image Analysis, 2024, 91: 103020.
- [17] Ilse M, Tomczak J, Welling M. Attention-based deep multiple instance learning[C]//International conference on machine learning. PMLR, 2018: 2127-2136.
- [18] Li Y, Chai X, Yang M, et al. Accurate prediction of disease-free and overall survival in non-small cell lung cancer using patient-level multimodal weakly supervised learning[J]. NPJ Precision Oncology, 2025, 9(1): 197.

- [19] 孙江洁, 苏炜欣, 周燕宁, 等. 早期非小细胞肺癌术后复发相关病理学特征及风险预测模型构建的研究现状[J]. 循证医学, 2025, 25(2): 124-128.
- [20] 吕超逸, 谢元, 邱露, 等. 综述: 深度学习在数字病理图像中的应用[J]. 中国医疗器械杂志, 2025, 49(3): 237-243.
- [21] Psutka S P, Gulati R, Jewett M A S, et al. A clinical decision aid to support personalized treatment selection for patients with clinical T1 renal masses: results from a multi-institutional competing-risks analysis[J]. European urology, 2022, 81(6): 576-585.
- [22] Liu H, Shi Y, Xu Y, et al. Agnostic-specific modality learning for cancer survival prediction from multiple data[J]. IEEE Journal of Biomedical and Health Informatics, 2024, 29(9): 6311-6322.
- [23] 杨清惠, 胡映雪, 倪萍蔚, 等. 1990—2021 年中国肺癌发病和死亡趋势分析及 2035 年预测研究[J]. 中国全科医学, 2026, 29(02): 256.
- [24] 葛坤坤, 金鑫, 仲建国, 等. 人工智能在肺癌诊断与治疗中的应用[J]. Chinese Journal of Oncology, 2025, 47(11).
- [25] 周世轩. 基于 ViT 与 ResNet-18 的深度学习模型在肺结节良恶性识别中的性能比较[J]. Advances in Clinical Medicine, 2026, 16: 1672.
- [26] 张熙明, 朱辉. 肺癌预测模型及其进展[J]. Advances in Clinical Medicine, 2024, 14: 98.
- [27] Cheerla A, Gevaert O. Deep learning with multimodal representation for pancancer prognosis prediction[J]. Bioinformatics, 2019, 35(14): i446-i454.
- [28] Shi J, Li C, Gong T, et al. Vila-mil: Dual-scale vision-language multiple instance learning for whole slide image classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11248-11258.
- [29] Li J, Chen Y, Chu H, et al. Dynamic graph representation with knowledge-aware attention for histopathology whole slide image analysis[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 11323-11332.

- [30] Tomczak K, Czerwińska P, Wiznerowicz M. Review The Cancer Genome Atlas (TCGA): an immeasurable source of knowledge[J]. Contemporary Oncology/Współczesna Onkologia, 2015, 2015(1): 68-77.
- [31] Fillioux L, Boyd J, Vakalopoulou M, et al. Structured state space models for multiple instance learning in digital pathology[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2023: 594-604.
- [32] Dietterich TG, Lathrop RH, Lozano-Pérez T. Solving the multiple instance problem with axis-parallel rectangles [J]. Artificial Intelligence, 1997,89(1-2): 31-71.
- [33] 谢卓恒, 伊鸣, 黄新瑞. 多实例学习在医学图像分析中的应用进展[J]. 集成技术, 2025, 14(2): 24-32.
- [34] Han K, Wang Y, Chen H, et al. A survey on vision transformer[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(1): 87-110.
- [35] Tu M, Huang J, He X, et al. Multiple instance learning with graph neural networks[J]. arXiv preprint arXiv:1906.04881, 2019.
- [36] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.